2026 秋季 · 9月22日

自然语言处理
项目实践

课程说明与第一次实践

郭宇航 · 北京理工大学计算机学院

nlp.hltbit.top/2026/

教师介绍

授课教师



郭宇航 Yuhang Guo

北京理工大学计算机学院
语言智能与社会计算研究所

硕士生导师
HLT 语言技术研究组

哈尔滨工业大学学士、硕士、博士
2014年加入北京理工大学

研究方向

自然语言处理与机器翻译

大语言模型与可靠智能体

多模态感知与交互

guoyuhang@bit.edu.cn 个人主页 ↗ 研究组主页 ↗

课程说明

这门课要练会什么

运行与修改

读懂数据、代码和配置，亲手完成一个可检查的实验。

设计与比较

设置基线和对照，选择指标，用相同条件比较方法。

解释与交付

用原始结果支持结论，让别人能够检查和再次运行。

> AI 可以帮助写代码；实验选择、结果核查和结论仍由你负责。

课程说明

课堂实践与论文复现

课堂：每周一个实践问题

- 跟随 Notebook 运行示例，再补核心函数。
- 比较结果、做一个自己的验证、解释取舍。
- 每周提供独立起点；未完成上周也能开始本周。

课外：小组完成一个限定实验

- 四人合作，选择一篇论文的部分实验。
- 用基线（比较起点）对照论文方法；再移除一个组件检验作用（消融），或做扩展。
- 提交报告、代码、结果与 PPT，参加集中汇报。

论文可以与当周课堂主题不同；不要求再开发一个完整应用系统。

课程说明

课程安排 · 9月—10月

日期	主题	练习重点
9月22日	工具环境与文本处理	规则改变了哪些统计和含义
9月29日	NLTK 与语料探索	统计口径、分布与原文证据
10月13日	Tokenizer、切分与截断	token 预算与完整证据
10月20日	昇腾平台与小模型训练	真实参数更新、保存与重载
10月27日	基线、指标与公平比较	相同数据、阈值与可信比较

国庆期间不上课；不安排需要同步到场或即时云资源的硬性任务。

课程说明

课程安排 · 11月—12月

日期	主题	练习重点
11月3日	数据干预与采样对照	区分新增信息与改变权重
11月10日	错误分析、人工评价与 LLM Judge	建立人工参照，核查自动评分
11月17日	Zotero 10 关键词阅读卡片	关键词质量、出处与保存行为
11月24日	论文部分复现汇报 · 第一场	实验结果、运行证据、成员答问
12月1日	论文部分复现汇报 · 第二场	同一提交截止、同一评分要求

课程说明

每周怎样学习

步骤	你要做什么	留下什么
先读示例	看清输入、处理过程和预期输出	对程序作用的解释
再做核心	补少量代码，运行教师提供的程序测试	代码和检查结果
独立判断	自拟输入，先预测，再只改一个条件比较结果	输入、预测、实际结果
形成结论	用具体输出说明变化和限制	说明变化原因，填写个人完成记录

完成核心后进入同目标进阶题。选做不是必交门槛，也不因付费工具或大模型加分。

课程说明

成绩组成

40%

课堂实践

提交方式以当周学生手册为准，保留本人实践记录。

20%

个人平台测验

每周约 5 题，独立作答，检查概念、预测和错误诊断。

40%

论文复现项目

实验、报告、代码与结果、PPT 及成员答问一并评价。

八周实践分别换算后等权汇总；平台测验单独计分，不在实践分中重复计算。

课程说明

提交到哪里、何时提交

材料	提交方式	截止时间
W01 个人实践包	每人在延河课堂上传 `W01_学号.zip`	9月22日 24:00
各周实践包	按当周学生手册提交，保留本人记录	各次上课当天 24:00
个人平台测验	每人完成相应测验，并确认已提交	各次上课当天 24:00
论文项目最终材料	联系人在延河课堂交组包，登记表填写提交记录	11月22日 24:00

> 群聊发送、只保存在草稿中、只填腾讯文档链接，都不等于完成延河课堂提交。

上传前检查文件能解压；平台故障或确实无法按时提交，应尽早联系教师并保留故障与提交记录。

课程说明

怎样使用 AI 与他人代码

- 可以用 AI 解释、调试、改写代码；提交中注明工具名称、用途和你核查过的部分。
- 使用作者代码、公开库或教师骨架，保留来源和版本，区分已有实现与自己的修改。
- 不得编造运行日志、数据、实验结果或个人贡献；不把他人输出说成本人运行。
- 每位成员都要解释自己的代码、输入与结果；“AI 生成的”不能代替解释。

API Key 不写入代码或作业；不向公共模型上传同学名单、学号或未授权数据。

课程说明

分组与论文登记

在延河课堂查看分组与论文登记入口 ↗

- 在表内核对自己的选课信息；如有遗漏或不一致，联系教师。
- 四人一组，在同一论文行填写姓名、学号；每人只加入一组，成员 1 为联系人。
- 只填写学生区域，不覆盖他人登记、论文要求、教师区和公式。
- 128人组成32组；P01—P36为论文号，G01—G32为确认后的组号。

先登记意向，再用少量样本试跑，检查数据、环境和耗时；登记后仍需教师确认范围。

课程说明

论文复现的时间安排

时间	完成事项
9月22日课后	阅读候选论文，协商组员，在登记表填写意向
9月29日后至10月13日课前	定位原文实验；试跑少量样本；填写选题试跑记录，由教师确认范围
10月27日课后	填写一页中期进展记录：当前结果、失败例、下一项实验
11月22日 24:00	所有组统一提交最终报告、PPT、代码和结果
11月24日 / 12月1日	按登记表确认的场次与顺序汇报

两批汇报均使用11月22日提交的版本。之后若需纠错，应标明变更并联系教师。记录模板见提交规范第5—6节。

课程说明

论文复现要做到什么程度

一个问题 · 一个数据集 · 一个基线 · 一个目标方法 · 一个变量

- 定位到原论文的具体小节、表格或图，说明你要检验哪条结论。
- 真正运行约定的核心方法，保存逐条结果；不能只展示下载的分数。
- 关键训练对照原则上用3个不同随机种子（控制初始化等随机过程的设置）分别运行；其他任务按选题要求重复或逐样本比较。
- 分析至少 10 个错误或边界案例；错误不足时补充正确但易混淆案例。

NLP 特色体现在文本任务、语言模型或表示、数据处理和评价方法；网页或聊天界面本身不构成复现。

课程说明

报告必须说明复现类型

类型	保留与改变	能得出什么结论
原设置部分复现	保留数据、模型、指标和协议；只做原表的一部分	可对照对应原结果，解释偏差
缩规模复现	减少样本、步数或检索库；保留比较逻辑	检验较小规模下的趋势，数值不能硬对齐
方法迁移验证	替换模型、领域或运行环境	说明新条件下的方法效果

> 选一个标签，在报告、PPT 的设置页和结果表旁一致标明。

课程说明

候选论文：按实验问题选

方向	编号	代表方法
分类与数据增强	P01—P05	TextCNN、fastText、EDA、TAPT、R-Drop
高效微调与句子表示	P06—P11	BitFit、LoRA、LM-BFF、SBERT、SimCSE、ConSERT
检索与上下文	P12—P15	DPR、HyDE、UPR、LongLLMLingua
推理、工具与长文本	P16—P21	CoT、Self-Consistency、ReAct、Self-Refine、RULER
行为测试与自动评价	P22—P25	CheckList、BERTScore、BLEURT、SelfCheckGPT
事实核验与评审偏差	P26—P30	FActScore、G-Eval、MT-Bench、FairEval、Format Bias

打开完整36篇清单与限定任务 ↗ 新增P31—P36：关键词、提示诊断与位置效应。

课程说明

选题前先确认能不能做

资源	检查内容
CPU / 常规电脑	数据、依赖、模型权重是否可获得；小样本能否运行
昇腾 NPU / MindSpore	作者 CUDA / PyTorch 代码不会自动兼容；确认可用框架和迁移范围
生成或评审 API	确认模型、接口能力、额度与费用；有 NPU 不等于已有 API
范围与替代路线	保存小样本输出与耗时；资源不合适时及时缩范围或换题

候选清单不是“全部题目已试跑等难”的承诺。P14、15、19、21、26、27、33 尤其要先做小样本试跑。

不要求购买 AI 会员或自费扩大算力；普通实现选择由小组决定，资源与范围变化及时登记。

课程说明

示例：把 TextCNN 题目说具体

可执行的范围

- 用MR电影评论数据做情感分类，固定并保存训练 / 验证 / 测试划分。
- 随机词向量与预训练词向量设置中选择两种对照。
- 固定其他配置，只再改变一个卷积窗口设置。

需要交的证据

- 三次训练的准确率（Accuracy）、各类别F1的平均值（Macro-F1），以及运行记录。
- 原文与本组设置差异表、逐条预测和案例分析。
- 说明固定划分不同于原论文交叉验证，不能硬比数字。

课堂第4次的训练实验可帮助理解训练流程；直接复制课堂结果不能代替本题实验。

课程说明

论文项目如何评分

维度	分值	看什么证据
论文理解与复现范围	8	原文定位、方法理解、差异披露
数据与实现	8	来源与划分、核心代码、真实运行记录
对照、指标与消融	8	公平基线、正确指标、一个变量的检验
错误分析与结论	8	逐样本证据、原因分析、适用边界
复现交付与汇报答问	8	可运行入口、清晰报告、成员解释

五项合计 40 分。结果未提升可以得到好评价；只跑通示例、缺少对照与解释，不能得到相应高分。

课程说明

最终报告：正文 4—6 页

部分	写清什么
1 论文与问题	完整文献来源、选题动机、原实验表 / 图位置、复现类型
2 方法与设置	核心架构、数据划分、基线、配置、指标与原设置差异
3 结果与消融	并列结果表、种子 / 重复次数、一个变量的对照
4 分析与结论	错误或边界案例、原因与限制、下一步验证、学习体会
附录	完整案例表、运行说明、四人贡献、代码与 AI 使用说明

正文 4—6 页含图表；参考文献和附录不计入。A4、正文 11—12 磅、单栏，图表标清单位与数据范围。

报告模板与填写说明 ↗　下载 Markdown 模板

课程说明

结果表与案例分析怎么写

配置	样本与协议	结果	证据路径
原论文目标行	填写原数据、模型和评价设置	引用原数值并注明表号	原论文表 / 图
本组基线	填写固定划分、种子或重复次数	均值与波动 / 配对统计	results/baseline…
本组目标方法	说明只改变了哪个方法组件	同一指标、同一测试样本	results/method…
本组消融	写出单一变化，其余条件固定	收益、代价和变化范围	results/ablation…

> 案例写“ID → 原文 / 正确标签 → 两种方法的输出 → 错误原因或边界”，不要只贴一张好看的成功截图。

课程说明

汇报 PPT：7 页讲清一个实验

页	主题	参考时间
1	题目、成员、复现范围与类型	20秒
2—3	原问题与核心方法：输入、处理、输出	35秒 + 40秒
4	实验设置、基线、指标与原文差异	45秒
5	主要结果：同一条件下并列比较	70秒
6	一个消融与代表性错误分析	50秒
7	结论、限制与分工证据	40秒

另用1分钟展示证据、1分30秒指定成员答问、30秒换组，共8分钟；每次16组。

下载可编辑 PPT 模板 ↗ 16:9；标题≥28磅，正文≥20磅，结果表≥18磅。

课程说明

最终提交包的目录与规范

```
NLP2026_G编号_P编号.zip
├── report.pdf
├── slides.pptx
├── slides.pdf
├── README.md
├── code/
├── configs/
├── results/
├── data/README.md
└── contributions.md
```

- README 写清环境、数据、命令、耗时和预期输出。
- 每条结果保留样本编号（ID）、正确标签或参考答案、模型输出与配置。
- 不打包虚拟环境、API Key、大权重和无权分发的数据。
- 大文件给出取得方式、版本和校验信息。

查看提交规范、选题试跑记录与成员贡献格式 ↗

第一次实践 · 目的

第一次实践：为什么从文本统计开始

面对48条模拟课程反馈，怎样找出值得回看原文的词？

- 让理论落到代码：追踪原文怎样变成词列表，再变成统计表。
- 让处理规则接受检验：大小写、网址和停用词会改变我们看到的结果。
- 建立可复查的实验习惯：先预测，用新输入验证，保留结果并说明边界。

> AI可以帮助写代码；你需要判断程序实际做了什么，以及输出能支持什么结论。

第一次实践 · 学习目标

完成这次实践后，你应能做到

学习目标	用什么证明
① 跑通并修改文本处理程序	在正确的Python内核运行NLTK示例； 修改规范化、计数函数，说明原文→词列表→统计表。
② 正确解释词频与覆盖范围	手算总出现次数TF与含词文档数DF；回到原文说明“出现得多”与“被更多条反馈提到”的区别。
③ 用对照验证处理规则	自拟输入并先写预测；保持输入不变、只改一个开关，用实际结果解释收益与信息损失。

测试通过只说明这些输入符合预期；还要解释新输入的结果，以及处理规则适用于什么情况。

完成必做后，可选技术名称提词、去重或按词的稀有程度赋权（IDF）实验。

第一次实践

今天的实践：从文本得到可解释的统计

输入	你修改的部分	输出
48 条课程反馈 课程自编教学语料	练习 A：规范化文本 练习 B：统计出现次数与含词文档数	词列表与词频表 原样、基础清洗、删停用词、保留否定词的对照
你自己的短文本	先写预期，再运行 对比时只改小写化或去网址开关	输入—预期—实际结果 一段有证据的解释

> 在同一个Notebook内完成。最终上传程序生成的个人ZIP，并完成5道平台测验，截止今天24:00。

资料与下载：先下载完整学生实践包 ↗

第一次实践

运行环境与工具的分工

工具	作用
Python	实际执行代码；编辑器不会替代解释器
Jupyter / VS Code Notebook	阅读并逐个运行单元，选择安装了依赖的Python内核
NLTK	Python文本处理库；本周依赖已包含它，无需额外下载语料

先进入解压后的 `nlp_w01` 目录，在终端执行：

```
python -m pip install -r requirements-notebook.txt
python -m jupyter lab
```

AI助手可选 Codex、Cursor、TRAE、WorkBuddy 或 DeepSeek API 工具。必做实验只需免费环境；AI额度与计费以账户为准。

第一次实践

先试一例：TF 与 DF

两条文档：`d1 = ["good", "good", "demo"]`
`d2 = ["good", "lesson"]`

good 的总出现次数 TF 是多少？包含 good 的文档数 DF 是多少？

TF = 3，DF = 2。同一条文档中重复出现会增加 TF，但这条文档的 DF 只计一次。

本课统计表的 TF 是全语料汇总次数；不能把 DF 直接说成独立学生人数。

第一次实践

比较的四套文本处理规则

方案	处理什么
raw 原样提词	直接提取英文字母串，保留大小写；网址字母也会进入
basic 基础清洗	去网址、整理空白、统一小写，再提词
stop_all 删除全部停用词	在 basic 基础上删除停用词表中的全部词
keep_neg 保留否定词	在 basic 基础上过滤停用词，但保留 no / not / never

> `The demo is not GOOD!` → 删除 not 后，统计中会丢失什么信息?

四套规则分别处理同一批原文。它们不是四个训练模型，也不是在原文上连续清洗四次。

第一次实践

怎样确认本次实践已经完成

任务	你要做什么	完成标准
预设程序测试	修改练习A、B两个函数，运行检查单元	教师提供的10项测试全部通过
个人输入测试	自拟大小写与否定词句子各1条；保留1条空输入	先写预期，再运行；3条输出均与预期一致
单因素实验	另写3条文本；先预测，比较小写化与去网址开关	比较时只改1个开关；解释实际变化与原因

程序显示的10/10、3/3分别表示上述两组测试全部通过，不是作业分数；它们不替代单因素实验。

三段短解释：TF与DF的区别、清洗规则的取舍、个人测试与单因素实验的发现。

第一次实践

今天提交什么，课后开始什么

今天 24:00 前

- 完成预设程序测试、个人输入测试和单因素实验。
- 填写TF/DF、清洗取舍、个人验证三段解释。
- 在Notebook第7节生成个人ZIP，上传延河课堂；独立完成5道测验。

论文线从今天开始

- 阅读候选论文，协商四人小组。
- 从延河课堂进入登记表填写意向；用少量样本试跑。
- 10月13日课前确认题目与复现范围。

打开在线实践手册 ↗　进入延河课堂 ↗

选题附录

候选论文 P01—P06

论文	限定复现任务	资源
P01 · TextCNN	两种词向量设置的分类对照	C/G
P02 · fastText	unigram 与加入 bigram 的效果和时间对照	C
P03 · EDA	固定分类器，比较无增强与两种增强	C/G
P04 · TAPT	直接微调与任务自适应预训练后微调	G
P05 · R-Drop	普通微调与 R-Drop 一致性正则	G
P06 · BitFit	完整微调、分类头与 BitFit 对照	G

C：常规电脑；G：加速器任务；L：生成或评审服务。都须先用少量样本试跑，确认资源可用。

选题附录

候选论文 P07—P12

论文	限定复现任务	资源
P07 · LoRA	编码器分类任务中完整微调与 LoRA	G
P08 · LM-BFF	手工模板提示微调与普通分类头	G
P09 · Sentence-BERT	BERT 平均池化与 SBERT 的相似度评价	C/G
P10 · SimCSE	无监督 SimCSE，检验 dropout 的影响	G
P11 · ConSERT	固定编码器与损失，比较表示增强	G
P12 · DPR	BM25 与 DPR 检索评价，不做全量训练	C/G

C：常规电脑；G：加速器任务；L：生成或评审服务。都须先用少量样本试跑，确认资源可用。

选题附录

候选论文 P13—P18

论文	限定复现任务	资源
P13 · HyDE	查询检索与假想文档检索对照	G+L
P14 · UPR	对固定 top-20 候选做条件概率重排	G
P15 · LongLLMLingua	完整上下文、等预算截断与压缩	G+L
P16 · Few-shot CoT	直接 few-shot 与 few-shot CoT	L
P17 · Zero-shot CoT	直接回答与两阶段 zero-shot CoT	L
P18 · Self-Consistency	单次 CoT 与多次采样多数聚合	L

C：常规电脑；G：加速器任务；L：生成或评审服务。都须先用少量样本试跑，确认资源可用。

选题附录

候选论文 P19—P24

论文	限定复现任务	资源
P19 · ReAct	直接回答与搜索—观察—作答循环	L
P20 · Self-Refine	初次输出与一次反馈修改	L
P21 · RULER	两个任务在 2k / 4k / 8k 下的效果	L
P22 · CheckList	MFT、INV、DIR 行为测试并重跑模型	C/G
P23 · BERTScore	BERTScore、BLEU 与人工评分相关性	C/G
P24 · BLEURT	公开 BLEURT 检查点的评价实验	C/G

C：常规电脑；G：加速器任务；L：生成或评审服务。都须先用少量样本试跑，确认资源可用。

选题附录

候选论文 P25—P30

论文	限定复现任务	资源
P25 · SelfCheckGPT	BERTScore / n-gram 一致性检测	C/G
P26 · FActScore	原子事实聚合与部分证据核验	G+L
P27 · G-Eval	公开分数复算 + 一个维度重新评审	L
P28 · MT-Bench Judge	人机一致性或位置偏差子实验	L
P29 · FairEval	位置偏差与双顺序聚合校准	L
P30 · Format Bias	内容等价下的格式偏好诊断	L

C：常规电脑；G：加速器任务；L：生成或评审服务。都须先用少量样本试跑，确认资源可用。

选题附录

候选论文 P31—P36

论文	限定复现任务	资源
P31 · TextRank	词共现图排序与词频基线	C
P32 · EmbedRank	相关性排序与MMR关键词去重	C/G
P33 · Contextual Calibration	标签条件概率的校准前后对照	C/G
P34 · Prompt Order	固定示例，检验排列顺序效应	L
P35 · Lost in the Middle	同一证据移到上下文首、中、尾	L
P36 · Demonstration Labels	真实、打乱标签与无示例对照	L

C：常规电脑；G：加速器任务；L：生成或评审服务。都须先用少量样本试跑，确认资源可用。